

jev-decision-service 0.1.3 · opensource 路径缺陷与修复

技术反馈单 | 真机环境：NVIDIA DGX Spark (GB10) + ollama + Qwen3-8B | 2026-09-24

0 结论

0.1.3 的框架、校准、OOD、分层路由这几块做得很好，但在真机上 opensource 路径（对接 vLLM / Ollama 本地模型）无法工作。我们用节点上的 ollama + Qwen3-8B 实测：原版连续 3 次全部失败；打好补丁后连续 3 次全部成功。

0 / 3 原版真机成功率	3 / 3 补丁后成功率	5 处 补丁修改点	13.2 s 单次决策耗时
------------------	-----------------	--------------	------------------

根因不是模型不行，而是解析器要求的键名和提示词要求的键名不一致。单测只喂了手工构造的标准格式，所以一直没暴露。

1 缺陷一：提示词与解析器键名不匹配

位置	现状	问题
_parse_jev_answer	只接受 {"type":"choice","choice":...} / "score" / "noul"	—（这是对的，Jev 原生契约）
OpenSourceProvider 的 system prompt	只说 "Answer every question using the declared choice options, numeric score levels, or noul yes probability"	从未要求模型把类型的值放在 choice / score / noul 这些键上
结果	模型按字面理解，输出 {"type":"choice","value":"clarification",...}	解析器找不到 choice 键 → ProviderError: choice is missing from probabilities

证据：逐字节比对显示，_parse_jev_answer 在 0.1.0 与 0.1.3 中完全相同（2574 字节），而提示词也一字未改——这个缺陷从 0.1.0 一路带到了 0.1.3。

修复：重写 system prompt，明确列出三种形状与键名、给出示例、并显式禁止 value 键。

2 缺陷二：真机上还有三类格式瑕疵

把键名问题修好之后，真机又连续暴露了三类新的失败。这说明不是改一句话就能解决，而需要一组输出容错：

#	真机现象	原代码行为	补丁做法
1	模型输出 value 键而非 choice/score 键	ProviderError: choice is missing from probabilities	提示词明确要求原生键名（治本）
2	概率和不严格为 1（如 0.4 + 0.3 + 0.2 + 0.1 ≠ 1）	校验器只容忍 0.01 偏差 → ProviderError: choice probabilities do not sum to one，且 retryable=False	交给校验器前温和归一化
3	score 越界（4 档被模型理解成 1~4，给出 4）	ProviderError: score is out of range	限幅到 [0, 选项数-1]；另支持把选项名映射为下标
4	多问嵌套 JSON 被截断（ollama 默认只生成 128 token）	解析失败，形状校验不通过	payload 显式传 max_tokens（默认 1024）

这四类错误原代码全部标为 retryable=False，意味着任何一处模型输出瑕疵都会让整单请求硬失败，而不会降级到 rules provider。建议：格式类错误标为 retryable=True，让 ResilientProvider 能兜底。

3 缺陷三：格式修好后，仍然走不到自动化

这是更深一层的问题，和格式无关。OpenSourceProvider 的默认 profile 是 calibrated=False，于是所有预测的 calibration_status 恒为 uncalibrated；而 PolicyConfig 默认 require_calibration_for_auto=True，会因此触发

uncalibrated_probability 并降级为 ask_clarification。

结论：不注入标定过的 DecisionHeadProfile，opensource 路径永远无法自动处置，只能反复追问。这是设计上的安全默认，但必须显式说明，否则接入方会困惑。

情形	calibration_status	policy 动作	是否被拦
默认 profile (calibrated=False)	uncalibrated	human_review (因 risk_level 偏高)	是
注入哨兵 D2 已标定 profile (T=1.14 , π_{train} =0.0312)	temperature_scaled	ask_clarification (原因变为需要澄清，不再是「未校准」)	否

实测证据：注入标定 profile 后，noul 概率被正确校正为 yes=0.6777 / no=0.3223，calibration_status 变为 temperature_scaled，policy 不再因未校准而拦截。哨兵 D2 已经产出了这组标定参数（温度 T 与训练先验 π ），可以直接提供给 opensource provider 使用。

4 真机证据 (节点 gx10-902c , ollama + Qwen3-8B)

被测版本	第 1 次	第 2 次	第 3 次	成功率
0.1.3 原版	失败	失败	失败	0 / 3
0.1.3 + 补丁	通过 13.3 s	通过 13.2 s	通过 13.2 s	3 / 3

原版典型报错 (3 次一致)

调用	报错
provider.evaluate(state)	ProviderError: invalid answer for intent: expected object (retryable=False)

补丁版输出 (一次调用并行产出 6 条类型化决策)

决策 id	类型	取值	主要概率
intent	choice	clarification	clarification 0.70 / information_request 0.20
risk_level	score	0.85	high 0.40 / moderate 0.30
needs_evidence	noul	True	yes 0.80 / no 0.20
needs_clarification	noul	True	yes 0.90 / no 0.10
allows_side_effect	noul	False	no 1.00 / yes 0.00
next_action	choice	ask_clarification	ask_clarification 0.60 / retrieve_evidence 0.20

5 补丁清单与用法

#	修改点	作用
1	OpenSourceProvider 的 system prompt	明确要求原生键名 (choice / score / noul)，给出三种形状与示例，显式禁止 value 键
2	payload 增加 max_tokens	默认 1024，避免 ollama 默认 128 token 截断多问 JSON
3	dataclass 增加 max_tokens: int = 1024	不同后端可调参
4	新增 _normalize_raw_answers()	兜住 value 键名 / 概率和不为 1 / score 越界 / 概率非数值四类瑕疵
5	在 _validate_answer_set 之前调用清洗函数	只做容错，不改校验器的合法性判断

用法：python3 patch_opensource_provider.py /path/to/src/jev_service/provider.py，幂等可重复执行；加 --check 只检测是否已修补。补丁后 29 个单元测试全绿。

6 顺带一个对作品有用的论据

这次真机测试还顺手提供了一个很有力的对比：通用大模型的输出是不可控的。同一个模型、同一个提示词，连续三次调用暴露了四类不同的格式瑕疵（键名错、概率和不为一、score 越界、token 截断），需要一整套容错代码才能接住。

输出可控性	垂类决策头（哨兵）	通用大模型（opensource 路径）
键名与结构	类型化输出，必然合法	自由文本，需解析与容错
概率约束	softmax 保证和为 1	模型自由给出，常不为 1
取值范围	由输出层维度保证	可能越界（如 4 档给出 4）
长度限制	不受影响	受 max_tokens 约束，可能截断
接入代价	直接可用	需 4 类容错 + 重试 + 降级

这一条可以直接写进作品的「架构选型」论证：高频、结构化、要求确定性的判断交给决策头（输出可控、亚毫秒、已校准）；只有罕见、模糊、需要语言理解的任务才升级到生成式——而升级路径必须配备输出容错与降级，否则线上会被模型的格式瑕疵击穿。

补丁：patch_opensource_provider.py | 真机脚本：jev_real_test.py / calib_check.py | 全部结论均来自 gx10-902c 节点实测