

jev 0.1.4 → 0.1.5 升级与效果对比报告

框架升级验证 · 上轮问题修复确认 · 端到端效果对比 · 新能力实测 · 残留问题

1 结论摘要

0.1.5 是一次结构性升级（代码 +47%，测试 35 → 70 项），方向完全正确：它把我上一轮报的三个框架级问题全部修掉，并新增了工业场景真正需要的四类能力。端到端主指标与 0.1.4 持平，代价是单条延迟上升约 21%。

+47% 代码量（2114 → 3107 行）	70 单元测试（0.1.4 为 35）	3 / 3 上轮问题全部修复	88.3% 自动化率（与 0.1.4 持平）
维度	0.1.4	0.1.5	判断
代码量 / 测试	2114 行 / 35 项	3107 行 / 70 项	结构升级
模块拆分	provider 单体 550 行	拆出 routing / normalization / http_provider / errors	可维护性↑
上轮 3 个问题	全部存在	全部修复	见第 3 节
StepFun 官方接入	无	StepFunProvider + json_schema	新能力
问题集注入	无（代码内）	JEV_QUESTION_PROFILE + roles	新能力
特征契约	无	维度/名称/量程/单位四道校验	新能力
离线评测工具	无	evaluation.py（分组指标 + Brier + ECE）	新能力
自动化率（主口径）	88.3%	88.3%	持平
单条延迟 p50	0.444 ms	0.536 ms	慢 21%（见 4.3）

2 0.1.5 新增了什么

新增能力	对工业场景的意义
QuestionProfile.roles（risk/action/evidence/clarification/side_effect）	领域问题可以叫 intervention_risk，不必再迁就 policy 的硬编码 id——我之前靠「故意沿用框架 id」绕过的那个约束，现在从设计上解掉了
DecisionHeadProfile.temperatures（逐问题温度）	多决策头可各自标定，不必再把温度强行挤进一个字段
prior_correction_head + prior_shift_assumption	先验修正只作用于指定 Noul，并要求显式声明 label_shift 假设（修了上轮问题 2）
feature_count / names / bounds / units	结构化头有了输入契约：维度、名称、量程、单位四道校验，不匹配时 accepts() 返回 False 交给文本模型，而不是报错
provider_disagreement → 强制人工复核	快头与生成式判断不一致时自动进复核，不再凭其中一个下结论
raw_value / raw_probabilities 保留	原始风险与校准后风险可追溯；原始高风险不会因温度缩放或升级而消失
provider_calls 调用审计（脱敏）	记录模型、尝试次数、耗时、结果与错误码，不含认证头与输入原文
StepFunProvider（json_schema strict + 有限退避）	云端升级层就绪；无密钥时不静默降级成规则，直接明确失败
TieredProvider.accepts() 路由 + 分歧/降级遥测	升级失败不再被伪装成 fast_head_accepted（修了上轮问题 1）

3 上轮所报 3 个问题的修复验证

3.1 降级遥测被静默掩盖 → 已修复

版本	触发方式	实际观测
0.1.4	升级层失败 (27B 返回空内容)	route=fast, route_reason=fast_head_accepted, 耗时 89 秒——完全看不出发生过升级, 也看不出失败
0.1.5 (不可重试)	升级层返回 404	明确报错 : {"error":"local-generative returned HTTP 404", "code":"http_error", "provider_status":404, "retryable":false}——配置错误直接暴露, 不伪装成成功
0.1.5 (可重试)	升级层连接被拒	route_reason=rare_class_support_insufficient;generative_failed:transport_error, warnings 含 provider_fallback:transport_error——降级原因可追溯

3.2 先验修正误伤全部 Noul → 已修复

版本	deployment_positive_rate=0.5 时的四个 Noul 概率	判断
0.1.4	fault 0.0027→0.0774 (预期) ; needs_evidence 0.052→0.631、needs_clarification 0.050→0.620、allows_side_effect 0.900→0.996 (全部误伤)	追问阈值 0.70 被逼近, 随时误触发
0.1.5	fault 0.0016→0.0465 (预期) ; 其余三项 0.0521 / 0.0500 / 0.9000 完全不变	作用域正确

3.3 Score 概率键名不校验 → 已修复 (且比建议更严谨)

0.1.5 的处理分三层 : ① 命名等级 (观察/计划/尽快/立即) 自动转下标并留`score\_labels\_to\_indices`警告 ; ② 标定后的 Score 强制使用规范数字键, 否则直接抛错 ; ③ choice 缺失的合法标签补零并告警, 额外标签或类型错配直接拒绝。我们的 evaluator 现在直接输出 "0"~"3", 实测 normalization_warnings 为空。

4 端到端效果对比 (同数据、同决策头、同种子)

两版使用同一套决策头权重 (heads.pt 复制沿用)、同一批 AI4I 留出集样本 (n=1000, seed=7)、同一条完整框架链路。0.1.4 侧保留我原来的集成写法, 0.1.5 侧改用新能力 (roles / 逐头温度 / 先验作用域 / 特征契约) ——即「各版各自的最佳写法」。

4.1 主指标

指标	0.1.4	0.1.5	变化
自动化率	88.3%	88.3%	持平
自动部分准确率	100.0%	100.0%	持平
故障漏放率	0.0%	0.0%	持平
正常设备误转率	9.1%	9.1%	持平
未标定响应数	— (该字段尚未存在)	0	全部经标定
引擎延迟 p50 / p95	0.444 / 0.474 ms	0.536 / 0.564 ms	慢 21%
吞吐	2,020 条/秒	1,848 条/秒	-8.5%

4.2 阈值扫描 : 安全拐点位置一致

urgent_score	0.1.4 自动化率	0.1.5 自动化率	0.1.4 漏放	0.1.5 漏放
1.6	39.8%	39.7%	0.0%	0.0%
2.0	47.9%	42.3%	0.0%	0.0%
2.5 (默认)	88.3%	88.3%	0.0%	0.0%
3.0	92.7%	90.5%	0.0%	0.0%

urgent_score	0.1.4 自动化率	0.1.5 自动化率	0.1.4 漏放	0.1.5 漏放
3.05	94.1%	94.1%	10.0%	10.0%

拐点位置两版完全一致（都在 3.0↔3.05 之间的悬崖）。中间两档 0.1.5 略保守（42.3% vs 47.9%、90.5% vs 92.7%），原因是 0.1.5 的风险门控同时比较校准后值与原始值（`value` 与 `raw\_value` 都在判据里），触发面更大——属于「原始高风险不因校准而消失」的预期代价，方向正确。

4.3 延迟为何上升 21%

0.1.5 在每次决策里新增了些固定开销：① 对完整请求（含特征、证据、元数据）做 SHA-256 幂等指纹；② 每个预测保留 raw_value / raw_probabilities 副本；③ warnings 去重与 route_reason 拼接；④ provider_calls 审计快照的深拷贝。绝对值仍是亚毫秒（0.536 ms/条），对本场景无实质影响；但若追求极限吞吐，①④ 是可优化项。

5 0.1.5 新能力的实测记录

能力	验证方式	实测结果
roles 映射	问题命名为 intervention_risk / next_action 等，PolicyConfig 只传 roles	策略层零改动，五条保护全部生效
逐头温度	temperatures={fault:0.916, fault_type:0.939, intervention_risk:0.320}	evaluator 只吐原始概率，框架完成标定；fault 0.99299 → 0.995538
先验作用域	prior_correction_head + label_shift + 部署先验 0.5	仅 fault 移动，其余 Noul 不变（见 3.2）
特征契约	缺 feature_units / 维度不符 / 超量程	三种非法输入均→ route=abstain，动作 abstain，不报 500
跨模型分歧	floor=0.995 强制升级到本地 8B（22 秒）	生成式判 intervention_risk=2.0 vs 快头 3.0 → provider_disagreement → 强制 human_review
调用审计	同上	provider_calls=1，含模型、尝试次数、耗时、结果、错误码
原始风险可追溯	对比 raw_value 与 value	raw=3.0 / value=3.0 等；升级后仍保留快头预测（last_safety_predictions）
StepFun 接入	—	未验证：无 STEPFUN_API_KEY。0.1.5 自己的验证记录同样标注 NOT_RUN

6 本次仍发现的 3 个残留问题（都不阻断）

#	问题	影响	建议
1	degraded 布尔未透传：TieredProvider 已置 degraded=True，但外层 ResilientProvider.degraded 仍为 False，engine.degraded 取的是后者	降级只能靠 route_reason / warnings 发现，单看 degraded 字段会误判为健康	ResilientProvider._collect 里同时带上 degraded
2	accepts() 吞掉了具体原因：StructuredHeadProvider.accepts() 内部捕获 ProviderError 后只返回 False，具体是维度/单位/量程哪一项不匹配丢失	调用方只看到 provider_unavailable，难以自查	accepts() 记录 last_reject_reason（如 invalid_features:unit_mismatch）并透出
3	OpenSourceProvider 默认 max_tokens=1024：对 7 问嵌套 JSON 会截断，finish_reason=length → incomplete_output（可重试）	自定义多问 profile 接本地模型时首次必失败	按问题数估算默认值，或在文档中提示；我已把服务默认值设为 2048

7 关于 0.1.5 对我方多数据集报告的核对：我的回应

0.1.5 附带的 docs/industrial-report-review.md 对我 9/28 的《Jev架构多工业数据集能力评测报告》提了 7 条方法论质疑。逐条核完：其中 5 条成立，我认可并会修正；2 条需补充数据后确认。

#	对方质疑	我的判断
1	「同一模型两种分布」但 BAcc 变化很大；单纯改类别比例不会改变 BAcc	成立，是我的表述问题。均衡口径是重训（训练集下采样后重训），不是同一模型换评测集。原报告措辞会造成误读，需改为「重训后的均衡口径」
2	高维表现差不能直接归因网络容量不足，需学习曲线与容量对照	成立。原报告写「高维必须扩容」属越界归因。应改为「64 维隐层在 474 维输入下欠拟合，容量对照实验待补」
3	自然分布 ECE 很低不等于可安全直接阈值路由	成立。应同时给出高风险召回、Brier 与自动放行的错误率——本次 0.1.5 验收里我已补上「自动部分准确率」「故障漏放率」
4	先验修正只在 label_shift 假设下成立；且 SKAB 均衡 ECE 反而更低，不能说所有数据集都恶化	成立，且我原文有事实错误。SKAB 均衡 ECE=0.0160 是所有数据集里最低的，我原文「5 个数据集一致复现 ECE 普遍恶化」不成立，必须更正为「除 SKAB 外」并说明 SKAB 的分布形态差异
5	SKAB / TEP 是时序数据，随机行划分可能泄漏（应按时间/设备/批次分组）	成立，这是最严重的一条。我的 multi_dataset_bench 用了随机行划分，SKAB 与 TEP 的结果存在泄漏风险，需改为按时序分组重跑后才可用作成绩
6	0.0006–0.0072 ms/条可能是批量摊销口径，不能与生成模型端到端时延比较	成立。应在报告中明确「推理核心单条口径 vs 端到端口径」，并避免跨口径大倍数对比。本次 0.1.5 验收已统一为完整链路口径
7	五任务跑通只支持「接口可适配」的工程结论，不能把效果归因于架构	成立。应把结论限定为工程适配性；架构有效性需消融实验

这份核对质量很高——尤其第 4、5 条指出了我原报告的事实错误与泄漏风险。建议尽快出 v2 修正版：修正 SKAB 表述、明确「重训」口径、把 SKAB/TEP 改为按时序分组划分重跑、补容量与架构消融。在评审面前主动更正，比被追问强得多。

8 部署现状

项	状态
生产服务	~/sentinel-stack → 框架 jev 0.1.5，端口 9000（公网 :9014）
基线备份	~/sentinel-stack-014 → 框架 0.1.4，需要对照时可 PORT=9001 启动
升级层	默认关闭；ESCALATE=1 开启，--generative stepfun 可切换 StepFun（需 STEPFUN_API_KEY）
特征契约	请求必须带 conversation_state.feature_units（C / C / rpm / Nm / min）
看板	http://61.172.235.130:9014/（已适配 0.1.5 契约，并显示原始风险 vs 校准后风险）
管理	cd ~/sentinel-stack && PORT=9000 ./stackctl.sh start stop restart status logs meta

哨兵 EdgeSentinel · 框架升级验收 · 数据均来自节点 gx10-902c 实测