

Jev 架构多工业数据集能力评测 · v2 修正版

Machine not Learning · 哨兵 EdgeSentinel 项目 · 全部数据为 DGX Spark (NVIDIA GB10 · CUDA 13.0) 节点实测 · 5 数据集 × 三种划分 × 两套口径 × 5 次重复

1 本版缘起与修正清单

0.1.5 附带的《industrial-report-review》对 9/28 的 v1 报告提出 7 条方法论质疑。我们逐条核对后认为 5 条成立，其中 2 条属于本报告的事实性错误。本版用重新设计的实验逐一验证，并把修正结果如实列出。

#	核对提出的质疑	本版处理方式	核对结论
1	「同一模型两种分布」表述有误——均衡口径实为重训（训练集下采样）	全文改称「均衡重训口径」，并同时给出「自然分布口径」	表述已修正
2	高维数据集表现差，不能直接归因于隐层容量（缺学习曲线/容量对照）	补 3 档容量对照（64→512），看学习曲线	原归因被推翻
3	低 ECE 不等于可以安全地做阈值路由	新增 4 档置信度阈值扫描，统计自动化率 / 高置信漏放 / 自动内错误率	质疑成立，本版给出关键新证据
4	「5 个数据集一致复现 ECE 恶化」与事实不符（SKAB 的 ECE 实为最低）	逐数据集列出 ECE，不再作一致性陈述	原表述错误，已更正
5	SKAB / TEP 是连续时序数据，随机行划分存在同段泄漏风险	新增「时序划分」与「跨单元划分」，并对每个配置做 5 次多种子重复	原结论偏乐观，已系统性下修
6	时延口径（推理核心 / 端到端）不能混比	同时给出「单条端到端」与「批量摊薄」两个口径并显式标注，禁止跨口径比较	原表口径混用，已澄清（两口径相差约 3500 倍）
7	五个任务跑通只能支持「接口可适配」，架构有效性需要消融	新增温度缩放消融（4 个数据集）	校准确有贡献（ECE 降 33~44%），但无法弥补判别力缺失

2 方法学变更（四项）

变更	v1 做法	v2 做法	为何必要
划分方式	全样本随机打乱后 60/20/20	在每个时序单元内按 60/20/20 顺序切分（时序划分）；另加按整组切分的「跨单元划分」	SKAB 是 34 次独立水泵试验、TEP 是 22 个工况各 960 点连续采样；随机打乱会让同一试验的前后段同时进入训练与测试
重复实验	单次运行（固定种子）	每个配置 5 个种子，报告 mean±std	部分数据集均衡测试集很小（SECOM 仅 34 条），单次结果不足为据
口径	自然分布 / 均衡分布并列，但均衡口径的语义未说明	明确标注：均衡口径 = 重训（训练集也下采样），属「判别力口径」，不能当作真实部署指标	避免读者把均衡指标误读为部署表现
架构贡献	无消融	对温度缩放做 on/off 消融	把「跑通」升级为「哪个组件真正起作用」

3 先验证两版可比（随机划分复现 v1）

在讨论差异之前，必须先排除「v2 实现与 v1 不同」这一混淆。把 v2 切换回 v1 的随机划分口径后，四个数据集的结果与 v1 报告一一对应：

数据集	v1 报告（随机划分·均衡）	v2 复现（5 次均值）	偏差	判定
AI4I 2020	0.9000	0.8917	-0.0083	在标准差范围内
SECOM	0.6333	0.6216	-0.0117	在标准差范围内

数据集	v1 报告 (随机划分·均衡)	v2 复现 (5 次均值)	偏差	判定
SKAB	0.8461	0.8470	+0.0009	在标准差范围内
Tennessee Eastman	0.6904	0.6967	+0.0063	在标准差范围内

四个数据集的偏差全部落在标准差以内，最大偏差 0.012。这证明 v2 与 v1 的可比性成立，后续的指标变化确实由划分方式导致，而非实现差异。

4 主结果：时序划分让判别力系统性下降

下表为均衡重训口径（与 v1 主表同口径），每个配置 5 次重复。

数据集	维度	随机划分 BAcc	时序划分 BAcc	跨单元划分 BAcc	Δ (时序-随机)
AI4I 2020	9	0.8917±0.0171	无时序语义	不适用	—
SECOM	474	0.6216±0.0217	0.4471±0.0638	不适用	-0.1745
SKAB	8	0.8470±0.0043	0.7462±0.0047	0.8130±0.0146	-0.1008
Tennessee Eastman	52	0.6967±0.0175	0.6385±0.0269	不适用	-0.0582

自然分布口径（贴近真实部署，不做任何下采样）下降更剧烈：

数据集	随机划分 BAcc	时序划分 BAcc	随机 MCC	时序 MCC	随机 AUC
AI4I 2020	0.7296±0.0568	无时序语义	0.6184	—	0.9546
SECOM	0.5206±0.0167	0.4956±0.0035	0.0619	-0.0206	0.6798
SKAB	0.8327±0.0037	0.5793±0.0087	0.7135	0.3050	0.8984
Tennessee Eastman	0.5000	0.5000	0.0000	0.0000	0.7845

三个时序数据集的判别力在时序划分下全部下降：SECOM -0.1745、SKAB -0.1008、TEP -0.0582。其中 SECOM 跌破随机水平（时序均衡 BAcc 0.4471、AUC 0.4969，MCC 为负），说明它在跨时段泛化上完全失效。原 v1 的 0.6333 显著高估了实际能力。

SKAB 的正例在试验后段集中出现，因此时序划分会造成严重先验漂移：训练集正例率 16%、校准集 95%、测试集 32%。这既解释了指标下滑，也说明 时序场景必须引入部署先验校正（与哨兵决策层 D2 的先验校正机制一致）。

5 容量对照：推翻「高维必须扩容」的归因

v1 把 SECOM（474 维）表现差归因于「474 维压进 64 维隐层严重欠拟合」。本版把隐层从 (64,32) 扩到 (512,256,128)——参数量提升约 30 倍——结果如下：

数据集	维度	(64,32)	(256,128)	(512,256,128)	最大增益
AI4I 2020	9	0.9000	0.8929	0.9000	+0.0000
SECOM	474	0.3529	0.3235	0.3824	+0.0295
SKAB	8	0.7390	0.7396	0.7422	+0.0032
Tennessee Eastman	52	0.5911	0.5990	0.6146	+0.0235

容量提升约 30 倍，四个数据集的最大增益仅 +0.0000 ~ +0.0295，其中 SECOM 扩到 512 仍然只有 0.3824（随机水平）。结论：瓶颈不在隐层容量，而在特征表示与数据本身的信噪比。v1 的归因不成立，已更正。

6 消融：校准确有贡献，但救不了判别力缺失

数据集	未校准 ECE	温度缩放后 ECE	降幅	Brier 前→后	温度 T
AI4I 2020	0.0890	0.0553	37.9%	0.0930→0.0903	1.642
SECOM	0.6350	0.4104	35.4%	0.5853→0.3831	4.263
SKAB	0.0579	0.0324	44.0%	0.1798→0.1764	1.480
Tennessee Eastman	0.3764	0.2518	33.1%	0.3785→0.2896	4.076

温度缩放一致地把 ECE 压低 33%~44%，证明该组件确有贡献（回应第 7 条质疑）。但必须同时看到：SECOM 校准后 ECE 仍为 0.4104、TEP 仍为 0.2518——校准只能修正「概率标度」，无法创造判别信息。对判别力本身不足的模型，校准之后依然不可用于自动化。

7 阈值扫描：低 ECE 不等于可以安全地阈值路由

这是核对第 3 条质疑的直接验证，也是本版最重要的新增证据。在时序划分 + 均衡重训口径下，按置信度阈值自动化，看三件事：自动化率、高置信漏放率（真故障被以高置信判为正常）、自动内错误率（自动处置部分判错的比例）。

数据集	阈值 0.7	阈值 0.9	阈值 0.95
AI4I 2020	89.3% / 4.3% / 8.0%	72.9% / 4.3% / 6.9%	60.7% / 4.3% / 5.9%
SECOM	64.7% / 47.1% / 59.1%	11.8% / 0.0% / 0.0%	2.9% / 0.0% / 0.0%
SKAB	48.5% / 11.6% / 14.6%	18.0% / 0.5% / 3.4%	11.4% / 0.1% / 1.7%
Tennessee Eastman	77.3% / 11.5% / 38.0%	44.5% / 3.1% / 26.9%	31.8% / 0.5% / 17.2%

（单元格式：自动化率 / 高置信漏放率 / 自动内错误率）

数据集	均衡 ECE	阈值 0.9 时自动内错误率	阈值 0.9 时自动化率	该阈值下是否可用
AI4I 2020	0.0587	6.9%	72.9%	可用（漏放稳定在 4.3%，属模型固定盲区）
SKAB	0.0392	3.4%	18.0%	可用但自动化率被压得很低
Tennessee Eastman	0.2141	26.9%	44.5%	不可用——每 4 条自动处置错 1 条
SECOM	0.3565	0.0%（因 88% 请求被拒自动化）	11.8%	不可用——th=0.7 时自动内错误 59.1%

结论：ECE 与「阈值路由是否安全」不是同一件事。SKAB 的 ECE（0.0392）与 TEP（0.2141）相差 5 倍，但真正的判据是「自动处置部分的错误率」。SECOM 在 0.7 阈值下自动处理 64.7% 的请求、其中 59.1% 判错、漏放 47.1%——如果只看 ECE 就上线，会把一半的故障静默归档。这正是核对第 3 条质疑的实证。

8 延迟口径澄清

v1 表中报告的 0.00057~0.00719 ms 实为批量摊薄值，而与之对比的生成式方案是单条延迟。两种口径相差三个数量级，不能并列。本版同时给出两个口径并显式标注：

数据集	单条端到端 (ms)	单条吞吐 (条/秒)	批量摊薄 (ms)	批量吞吐 (条/秒)	倍数
AI4I 2020	0.0461	21,681	0.000014	73,868,950	3,294×
SECOM	0.0508	19,699	0.000077	12,957,091	659×
SKAB	0.0455	21,966	0.000013	74,397,015	3,502×
Tennessee Eastman	0.0454	22,024	0.000017	60,505,812	2,671×

按单条端到端口径（含张量构造）：0.0454~0.0508 ms，对比生成式单条 11 279 ms 约为 24.5 万倍。批量摊薄值仅适用于「批量离线扫描」场景，不能用于实时报警分诊的对比。

9 v1 结论的修正清单

v1 的结论	v2 判定	依据
跨领域可用性成立（5 个子领域零改动跑通）	降级为「接口可适配」	时序划分下 SECOM 完全失效（AUC 0.4969）、TEP 在自然分布下恒判故障（BAcc 0.5000、MCC 0）
低维（8~9 维）结构化传感器是优势区	部分保留，数值下修	SKAB 时序均衡 BAcc 0.7462（原 0.8461）、跨单元 0.8130；AI4I 随机均衡 0.8917
高维必须扩容（474 维压进 64 维隐层欠拟合）	推翻	容量扩至 (512,256,128) 后 SECOM 仅 0.3824，四数据集最大增益 +0.0295
5 个数据集一致复现「校准随部署分布漂移」	更正为部分成立	SKAB 校准后 ECE 0.0392 为全部最低，「一致恶化」不成立；漂移幅度各数据集差异显著
延迟 0.0006~0.0072 ms/条	更正口径	该数值为批量摊薄；单条端到端为 0.0454~0.0508 ms，两者相差约 3500 倍
少数类是主要短板（AI4I Choice 宏 F1 0.211）	保留	TWF 46 条 / RNF 18 条，样本量不足，与容量无关

10 仍未解决的局限（如实列出）

局限	影响	后续动作
SECOM / TEP 的判别力本身不足（时序划分下接近随机）	不能声称这两类场景可用；半导体与连续流程需要专门的特征工程	尝试按工况归一化、只用稳态段、加入过程变量的一阶差分与滑动统计
SKAB 时序划分造成严重先验漂移（训练 16% / 校准 95% / 测试 32%）	校准集无法代表部署分布，温度缩放被误导	引入部署先验校正（logits 加 log 先验比），与哨兵 D2 机制统一
部分数据集测试样本量小（SECOM 均衡仅 34 条）	指标标准差可达 ±0.064，细粒度比较的统计功效不足	改用交叉验证或扩大采样次数；对外只报区间不报点值
只有 5 个工业数据集、4 个可评 Noul	跨领域结论的覆盖面有限	补 CWRU 轴承振动、UCI-447 液压系统，覆盖旋转机械与液压传动

本版的立场：宁可把指标改低，也不留下会被复现推翻的结论。v1 中过于乐观的三条已在本版修正，其中两条属于我们的错误。