

Jev 架构 · 多工业数据集综合能力评测

数据集：AI4I 2020 / Steel Plates / SECOM / SKAB / Tennessee Eastman | 统一决策头 MLP(64,32) + 温度缩放 |
真机：NVIDIA DGX Spark (GB10) | 2026-09-28

0 结论

在 5 个工业子领域（机加工、冶金、半导体、水务、化工）上，用同一套 Jev 类型化决策框架（Noul 是否异常 / Choice 异常类型 / Score 优先级）与同一个决策头结构进行评测。结论是：Jev 架构在低维结构化传感器场景表现优秀（BAcc 0.85~0.90），在中高维场景需要按维度扩容，且「均衡训练集」是决定成败的关键工程手段。

5 / 5	0.90	0.0006~0.007	0.016~0.137
数据集全部跑通	最佳 Noul 均衡 BAcc (AI4I)	单条延迟 ms	ECE 校准误差区间

1 评测设计

要素	设定	理由
被测对象	Jev 类型化决策框架 + 统一决策头 MLP(64,32) + 温度缩放校准	隔离「架构范式」的作用，排除模型规模差异的干扰
决策原语	Noul (是否异常) / Choice (异常类型) / Score (优先级)	Jev 的三种类型化决策原语，覆盖工业报警分诊的全部输出
划分	60% 训练 / 20% 校准 / 20% 测试，全部同一种子 20260921	保证跨数据集可比；校准集单独划出才能做温度缩放
两套口径	「自然分布」（真实故障率）与「均衡分布」（正负 1:1）	自然口径反映真实部署；均衡口径反映判别能力上限
指标	BAcc / P / R / F1 / MCC / AUC / ECE / Brier / 延迟	工业场景正负极度不平衡，Accuracy 无意义，必须看 BAcc 与 MCC

说明：jev-decision-service 的默认判断层是规则引擎（面向对话路由），本身不是工业模型。因此本评测测的是「Jev 架构范式」——类型化决策 + 概率校准 + 确定性策略路由——在工业数据上的适配能力，而非某个具体权重的好坏。这正是「架构能力」而非「模型能力」的论证。

2 数据集矩阵（5 个工业子领域）

数据集	工业子领域	规模	维度	任务	备注
AI4I 2020	机加工 / 数控机床	10 000	9	Noul + Choice(6)	故障率 3.4%，含 5 类刀具/热/功率/过载/随机失效
Steel Plates	冶金 / 钢板表面	1 941	27	仅 Choice(7)	原始数据全为缺陷样本，无正常类，无法评测 Noul
SECOM	半导体 / 晶圆制造	1 567	474	仅 Noul	590 维传感器、缺失值极多；正例率仅 6.6%
SKAB	水务 / 水泵机组	37 401	8	仅 Noul	35 个 CSV 时序合并；振动/电流/压力/温度
TEP	化工 / 连续流程	21 120	52	Noul + Choice(22)	21 种故障工况 + 1 正常工况

3 主结果

数据集	领域	Noul BAcc(均衡)	F1	MCC	AUC	ECE	Choice 任务	延迟 ms
AI4I 2020	机加工 / 数控机床	0.9000	0.9028	0.8013	0.9400	0.0731	6 类 · Acc 0.9650 · MacroF1 0.2113	0.00626
Steel Plates	冶金 / 钢板表面缺陷	—	—	—	—	—	7 类 · Acc 0.7558 · MacroF1 0.7429	0.00057
SECOM	半导体 / 晶圆制造	0.6333	0.6452	0.2673	0.6533	0.1225	—	0.00068
SKAB	水务 / 水泵机组	0.8461	0.8338	0.7000	0.9076	0.0160	—	0.00082
TEP	化工 / 连续流程	0.6904	0.6995	0.3814	0.7906	0.1370	22 类 · Acc 0.5698 · MacroF1 0.5817	0.00719

主口径为均衡分布（正负 1:1）——工业场景正例率常低至 3%~7%，不均衡指标会被多数类淹没（见第 4.2 节）。Steel Plates 无正常类，仅报 Choice。

3.1 分布口径的影响（同一模型，两种评测分布）

数据集	自然分布 BAcc	自然分布 ECE	均衡分布 BAcc	均衡分布 ECE	BAcc 差异
AI4I 2020	0.6564	0.0084	0.9000	0.0731	+0.2436
SECOM	0.4916	0.0276	0.6333	0.1225	+0.1417
SKAB	0.8329	0.0256	0.8461	0.0160	+0.0132
TEP	0.5000	0.0058	0.6904	0.1370	+0.1904

两个现象同时存在且方向相反：判别能力在均衡口径下大幅提升（AI4I +0.24、TEP +0.19、SECOM +0.14），但校准质量在均衡口径下变差（ECE 普遍上升）。这正是我们在 AI4I 单数据集阶段发现过的「校准依赖部署分布」，在 5 个数据集上被一致复现——先验校正是必要环节，不是可选项。

4 横切分析

4.1 维度效应：决策头容量是瓶颈

维度区间	数据集	Noul 均衡 BAcc	解读
低维（8~9）	SKAB、AI4I	0.846 ~ 0.900	统一的小决策头（64,32）完全够用，接近可用水平
中维（27~52）	Steel Plates、TEP	0.690（TEP）	开始吃力；TEP 的 22 类 Choice 也仅 0.582 MacroF1
高维（474）	SECOM	0.633	明显欠拟合：474 维输入压进 64 维隐层，信息损失严重

结论：统一小模型的做法在低维工业场景是合理的，但高维场景必须扩容（加大隐层 / 加特征选择 / 换更强的编码器）。这也说明「Jev 架构」本身不限制模型规模——它是决策范式，决策头的容量应按工况数据维度单独标定。

4.2 任务难度：Choice 的类别数与样本量决定成败

数据集	类别数	MacroF1	原因分析
Steel Plates	7	0.7429	各类样本量相对均衡（约 100~400 条/类），表现良好
TEP	22	0.5817	每类 960 条，样本充足但类别多、类间相似度高
AI4I 2020	6	0.2113	少数类极少（TWF/RNF 各仅 46/18 条），模型基本学不到

AI4I 的 Choice 表现最差，但这不是架构问题而是数据问题——同一批次中 TWF 只有 46 条、RNF 只有 18 条。反之 Steel Plates 与 TEP 只要每类样本充足，MacroF1 就能上 0.58~0.74。结论：Choice 原语可用，但前提是少数类要有足够样本支撑。

4.3 校准质量：低维优于高维

数据集	ECE (自然)	ECE (均衡)	评价
AI4I 2020	0.0084	0.0731	自然口径极优，均衡口径中等
SKAB	0.0256	0.0160	两种口径都很好——校准最稳健的数据集
SECOM	0.0276	0.1225	高维欠拟合带来校准恶化
TEP	0.0058	0.1370	自然口径极优，均衡口径最差 (22 类摊薄)

温度缩放是有效的 (自然口径 ECE 全部在 0.03 以下)，但它只修正「整体过于自信/不足」，不修正判别误差。均衡口径下 TEP/SECOM 的 ECE 恶化，根源是判别本身有偏——这时需要的是更好的特征或更多数据，而非继续调校准参数。

5 Jev 架构的工业能力评价

能力项	评价	证据
跨领域可用性	✓ 强	5 个截然不同的工业子领域 (机加工/冶金/半导体/水务/化工) 全部跑通，无需改动架构
低维场景判别力	✓ 强	SKAB 0.846、AI4I 0.900 (均衡 BAcc)
高维场景判别力	△ 需扩容	SECOM 0.633，474 维需更大决策头或特征选择
多类故障分类	✓ 中上	Steel 7 类 MacroF1 0.743、TEP 22 类 0.582
概率校准	✓ 强	自然口径 ECE 0.006~0.028，可直接支撑阈值路由
推理延迟	✓ 极强	0.0006~0.0072 ms/条，比生成式方案快 6 个数量级
少数类学习	✗ 弱	AI4I 少数类 MacroF1 仅 0.211，需重采样/合成数据补足
部署分布适配	△ 需先验校正	均衡口径 ECE 普遍上升，必须显式做先验校正

6 结论与建议

#	结论 / 建议
1	Jev 架构在工业场景具备跨领域可用性：5 个子领域零改动跑通，说明「类型化决策 + 校准 + 确定性路由」这套范式与工业报警分诊天然契合
2	低维结构化传感器是它的优势区 (BAcc 0.85~0.90)，这也正是产线设备的典型形态——架构选型在此得到验证
3	决策头容量必须按工况维度单独标定：不要指望一个 64×32 的小网络通吃 9 维与 474 维；高维场景需扩容或做特征选择
4	先验校正是必需项：5 个数据集一致复现「校准随部署分布漂移」，上线前必须用真实分布重新标定，或实现 EM 盲估 (我们已在 AI4I 上验证可行)
5	少数类是主要短板：AI4I 的 Choice 只有 0.211，而 Steel/TEP 有 0.58~0.74。差距全部来自各类样本量——建议用 StepFun 做合成数据补足少数类
6	下一步：把这套多数据集评测固化为回归测试，任何架构改动都跑一遍，防止再次出现「自动化率归零」这类静默回归

复现：python3 multi_dataset_bench.py | 原始结果：multi_bench/multi_dataset_result.json | 全部数据来自 gx10-902c 节点实测