

哨兵 EdgeSentinel · System One 决策层评估报告

硬件：NVIDIA DGX Spark (GB10 , 121 GiB 统一内存 , CUDA 13.0) 数据集：AI4I 2020 评估日期：2026-09-21

0 实验配置

项目	配置
总样本	10 000 条 (故障 339 条 , 占 3.39%)
数据划分	训练 6000 / 校准 2000 / 测试 2000 (随机种子 20260921)
状态编码器	9 维特征：气温、过程温度、转速、扭矩、磨损 + 温升、机械功率、磨损-负载耦合、单位转速温升
决策头	MLP , 隐藏层 (64, 32) , ReLU , max_iter=800 , random_state=20260921
校准方法	温度缩放 (校准集最小化 NLL ; 二元用 logit , 多元用 log-proba 作 logits)
生成式基线	本地 Qwen3-27B GGUF (ollama , 100% GPU 卸载) , 实测 83.7 s/条 (开思考) / 0.7 s/条 (关思考)

1 Noul：是否真实故障 (二元判定)

0.9616 ROC-AUC	0.7683 PR-AUC (平均精度)	0.8300 Balanced Accuracy	0.6646 MCC
指标	数值	说明	
Precision (精确率)	0.6812	判为故障的样本中 , 68.1% 真为故障	
Recall (召回率 / 灵敏度)	0.6714	真实故障中被抓到 67.1%	
F1	0.6763	—	
Specificity (特异度)	0.9886	正常样本几乎不误报	
Accuracy	0.9775	受不平衡影响 , 参考即可	
Balanced Accuracy	0.8300	更可信的综合指标	
MCC (马修斯相关系数)	0.6646	不平衡数据下最稳健的单值指标	
ROC-AUC	0.9616	排序能力强	
PR-AUC	0.7683	远高于随机基线 0.034	

混淆矩阵 (测试集 n=2000)

	预测正常	预测故障
实际正常	1908	22
实际故障	23	47

读法：准确率 97.75% 看着漂亮，但那是因为 96.6% 的样本本来就是正常。真正该看的是 Balanced Accuracy 0.830 和 MCC 0.665——它们才反映模型在两类上的真实表现。

2 校准质量

指标	校准前	校准后
温度系数 T	1.000	1.183
ECE (10 分箱)	0.0073	0.0066
MCE (最大校准误差)	0.2652	0.2594
Brier Score	0.0155	0.0156

校准后可靠性曲线

预测概率	实际发生率	样本数
0.004	0.004	1853
0.148	0.069	29
0.260	0.118	17
0.346	0.312	16
0.443	0.438	16
0.532	0.273	11
0.648	0.571	14
0.746	0.556	9
0.848	0.750	12
0.967	0.957	23

分布敏感性 (同一模型，切换评估分布)

评估分布	Accuracy	ECE	Brier
自然分布 (3.4% 故障)	0.978	0.0066	0.0156
均衡分布 (50%，20 次抽样)	0.829 ± 0.006	0.1675	0.1183

必须写进报告的发现：校准是相对部署分布的。同一个模型，在自然分布下 ECE 仅 0.0066，换到均衡分布就劣化到 0.1675。部署时若真实故障率与训练分布不同，必须重新校准或做先验校正 (logits 加 log(先验比))。主动披露这一点比掩饰更能体现工程深度。

3 Choice：故障类型 (6 分类)

类别	Precision	Recall	F1	Support
No Failure	0.9826	0.9979	0.9902	1927
TWF (刀具磨损)	0.0000	0.0000	0.0000	6
HDF (散热失效)	0.8400	0.7241	0.7778	29
PWF (功率失效)	1.0000	0.7222	0.8387	18
OSF (过载失效)	0.8000	0.2857	0.4211	14
RNF (随机失效)	0.0000	0.0000	0.0000	6
宏平均	0.6038	0.4550	0.5046	2000
加权平均	0.9735	0.9805	0.9758	2000

混淆矩阵

实际 \ 预测	NoFail	TWF	HDF	PWF	OSF	RNF
No Failure	1923	0	4	0	0	0
TWF	6	0	0	0	0	0
HDF	8	0	21	0	0	0
PWF	4	0	0	13	1	0
OSF	10	0	0	0	4	0
RNF	6	0	0	0	0	0

根因不是模型不行，是数据不够。测试集里 TWF 只有 6 条、RNF 只有 6 条——模型根本没机会学。解决办法：① 用 StepFun 合成少数类样本；② 合并稀有类别为“其他”；③ 换用样本更均衡的数据源（如 CWRU 轴承数据集每种故障都有上千样本）。

4 Score：维护优先级（0~3 序数）

等级	Precision	Recall	F1	Support
0·观察	1.0000	1.0000	1.0000	55
1·计划	1.0000	0.9881	0.9940	758
2·尽快	0.9867	0.9923	0.9895	1045
3·立即	0.9448	0.9648	0.9547	142
宏平均	0.9829	0.9863	0.9846	2000

序数指标	数值
QWK（二次加权 Kappa）	0.9872
MAE（平均绝对误差）	0.0110
误差 ≤1 级的比例	1.0000
Accuracy	0.9890

这一项的数字不能拿去吹。0~3 的标签是我们自己用磨损/温升/负载阈值派生的规则，不是人工标注。QWK 0.987 只说明“模型完美学会了我们写的那条规则”，不代表它学会了真实的维护优先级。正式版必须由领域专家或用 StepFun 重新标注。

5 阈值 — 自动化率 — 准确率权衡（核心卖点）

阈值	自动化率	自动部分 Precision	自动部分 Recall	人工复核率	自动部分错误率
0.60	98.7%	0.7586	0.7333	1.3%	0.0152
0.70	97.2%	0.8182	0.7660	2.8%	0.0098
0.80	95.9%	0.8857	0.7750	4.1%	0.0068
0.90	93.8%	0.9565	0.7586	6.2%	0.0043
0.95	91.5%	1.0000	0.7083	8.5%	0.0038
0.98	87.2%	1.0000	0.6000	12.8%	0.0034

汇报时这么说：「阈值设 0.9，93.8% 的报警可以自动处置，自动部分的精确率 95.65%，只剩 6.2% 需要人工看一眼，自动部分错误率仅 0.43%。」——而这张表只有做了概率校准才做得出来。

6 延迟与吞吐

指标	数值
p50 延迟	0.097 ms
p95 延迟	0.100 ms
p99 延迟	0.100 ms
吞吐	10 288 条/秒 (三问同出)
生成式基线 (27B，关思考，单问)	700 ms/条
生成式基线 (27B，开思考，6 问 JSON)	83 700 ms/条
加速比 (vs 开思考)	约 861 000×
加速比 (vs 关思考单问)	约 7 200×

诚实提示：86 万倍这个数字别当卖点讲——两者能力不同（决策头只吃结构化传感器，27B 能处理任意文本）。正确说法是：高频结构化判断交给 System One，罕见/模糊的才升级到生成式，这正是三层路由的意义。

7 与生成式方案对照 (均衡集 n=40)

指标	生成式 27B 自报	哨兵决策头	对比
平均置信度	0.912	0.978	—
实际准确率	0.475	0.829	1.75×
ECE	0.4375	0.1675	2.6× 更准
Brier	0.4325	0.1183	3.7× 更准
延迟	700 ms	0.097 ms	7 202×

这是整套方案的立论基石。生成式模型自称 91.2% 把握，实际只对 47.5% (近乎随机)，ECE 高达 0.4375——典型的 RLHF 类系统性过度自信。校准决策层正是为解决它而存在。

8 已知局限 (交接必读)

局限	影响	改进方向
少数类样本极少 (TWF 6、RNF 6)	Choice 宏平均 F1 仅 0.505	StepFun 合成 / 换 CWRU 数据集 / 稀有类合并
Score 标签为自己派生的规则	0.987 的 QWK 无真实含金量	领域专家或 StepFun 重新标注
校准依赖部署分布	换分布后 ECE 从 0.0066 升至 0.1675	先验校正 / 上线前用真实分布重新校准
仅单一数据源 AI4I	未验证跨设备、跨工况泛化	补充 CWRU / C-MAPSS / XJTU-SY
编码器为手工特征，非端到端	未利用报警文本等 unstructured 信息	接入文本 encoder (torch + ModelScope 小模型)
尚未服务化 / 无界面 / 未接 StepFun	当前只是评估脚本	D2 起工程化

评估脚本：full_eval.py 复现命令：cd ~/jev-service && python3 full_eval.py
全部数据源自 gx10-902c 节点真机实测，2026-09-21