

通用大模型 vs 垂类决策头 · 对决实验报告

硬件：NVIDIA DGX Spark (GB10) 数据：AI4I 2020 评估集：n=140 均衡抽样 日期：2026-09-22

0 实验设计 (为什么要这么比)

核心问题：在工业设备状态判定这类「结构化数值 → 类型化决策」任务上，通用大模型到底比我们训练的垂类小网络强还是弱？

要素	设定
数据	AI4I 2020；训练 6000 / 校准 2000 / 测试 2000 (种子 20260921)
评估集	均衡抽样 n=140 (故障 70 / 正常 70) ——避免「全判正常」刷分
垂类选手	9 维状态编码 → MLP(64,32) 三决策头 → 温度缩放校准
通用选手	Qwen3-27B、Qwen3-8B (本地 GGUF，100% GPU 卸载，temperature=0)
信息量档位	L0 裸数值 / L1 加单位与正常范围 / L2 再加故障机理 + few-shot 示例
决策方式	一次调用同时输出三个决策 (对标 Jev 并行采样)：故障？类型？严重程度？
统一指标	Accuracy / Balanced Acc / Precision / Recall / F1 / MCC / ECE / Brier / 格式合规率 / 延迟

公平性说明：三方吃完全相同的一批样本。大模型拿的是同一组数字写成的一句话，垂类模型拿的是同一行传感器读数。刻意给大模型加了 L1/L2 两档知识注入——如果这样它仍然打不过，那结论就不是「提示没写好」，而是任务性质本身决定的。

1 总表：谁更强

选手	Acc	B.Acc	F1	MCC	类型宏F ₁	严重度Acc _c	ECE	Brier	合规	延迟ms
哨兵决策头 (MLP+校准)	0.829	0.829	0.797	0.692	0.588	0.986	0.1658	0.1202	100%	0.097
Qwen3-27B · 裸数值	0.493	0.493	0.000	-0.085	0.136	0.079	0.4488	0.4491	100%	10593.9
Qwen3-27B · +知识	0.643	0.643	0.648	0.286	0.158	0.600	0.2286	0.2741	100%	10995.2
Qwen3-27B · +示例	0.643	0.643	0.648	0.286	0.158	0.829	0.2421	0.2855	100%	11278.6
Qwen3-27B · +示例·思考链(超时)	0.700	0.500	0.000	0.000	0.214	0.050	0.2000	0.2500	0%	90090.7
Qwen3-8B · 裸数值	0.529	0.529	0.612	0.063	0.100	0.164	0.3650	0.3847	100%	2803.4
Qwen3-8B · +知识	0.514	0.514	0.673	0.120	0.027	0.471	0.3407	0.3619	100%	2873.8
Qwen3-8B · +示例	0.543	0.543	0.686	0.212	0.048	0.200	0.4093	0.4138	100%	2825.2
基线：全判正常	0.500	0.500	0.000	0.000	0.137	0.307	0.5000	0.5000	100%	—
基线：随机猜	0.457	0.457	0.472	-0.086	0.144	0.257	0.0000	0.2500	100%	—

读法：B.Acc (平衡准确率) 是主指标——它把故障类和正常类一视同仁，不会被「96% 都是正常样本」这种不平衡带偏。MCC 越接近 1 越好、0 等于瞎猜。ECE/Brier 衡量概率可不可信，越低越好。合规 是输出能被解析成合法决策的比例。

2 分任务拆解

2.1 Noul：是否真实故障 (精确率 / 召回率)

选手	Precision	Recall	F1	B.Acc
哨兵决策头 (MLP+校准)	0.979	0.671	0.797	0.829
Qwen3-27B · 裸数值	0.000	0.000	0.000	0.493
Qwen3-27B · +知识	0.639	0.657	0.648	0.643
Qwen3-27B · +示例	0.639	0.657	0.648	0.643
Qwen3-27B · +示例·思考链(超时)	0.000	0.000	0.000	0.500
Qwen3-8B · 裸数值	0.520	0.743	0.612	0.529
Qwen3-8B · +知识	0.507	1.000	0.673	0.514
Qwen3-8B · +示例	0.522	1.000	0.686	0.543
基线：全判正常	0.000	0.000	0.000	0.500
基线：随机猜	0.459	0.486	0.472	0.457

2.2 Choice：故障类型 (6 类) 与 Score：严重度 (0~3)

选手	类型Acc	类型宏F1	严重度Acc	严重度宏F1	严重度MAE	误差≤1级
哨兵决策头 (MLP+校准)	0.793	0.588	0.986	0.988	0.014	1.000
Qwen3-27B · 裸数值	0.514	0.136	0.079	0.037	1.721	0.386
Qwen3-27B · +知识	0.364	0.158	0.600	0.553	0.500	0.900
Qwen3-27B · +示例	0.364	0.158	0.829	0.808	0.214	0.957
Qwen3-27B · +示例·思考链(超时)	0.750	0.214	0.050	0.024	1.750	0.350
Qwen3-8B · 裸数值	0.200	0.100	0.164	0.120	1.464	0.479
Qwen3-8B · +知识	0.057	0.027	0.471	0.345	0.614	0.914
Qwen3-8B · +示例	0.086	0.048	0.200	0.140	1.236	0.629
基线：全判正常	0.521	0.137	0.307	0.117	0.879	0.814
基线：随机猜	0.171	0.144	0.257	0.233	1.143	0.671

3 提示工程能不能救回来？

模型	L0 裸数值	L1 +知识	L2 +示例	L2 +思考链	(垂类决策头)
Qwen3-27B	0.493	0.643	0.643	0.500	0.829
Qwen3-8B	0.529	0.514	0.543	—	0.829

4 概率可不可信 (ECE / Brier)

选手	ECE	Brier
哨兵决策头 (MLP+校准)	0.1658	0.1202
Qwen3-27B · 裸数值	0.4488	0.4491
Qwen3-27B · +知识	0.2286	0.2741
Qwen3-27B · +示例	0.2421	0.2855
Qwen3-27B · +示例·思考链(超时)	0.2000	0.2500

选手	ECE	Brier
Qwen3-8B · 裸数值	0.3650	0.3847
Qwen3-8B · +知识	0.3407	0.3619
Qwen3-8B · +示例	0.4093	0.4138
基线：全判正常	0.5000	0.5000
基线：随机猜	0.0000	0.2500

5 延迟

选手	单条延迟 p50 (ms)	样本数
哨兵决策头 (MLP+校准)	0.097	140
Qwen3-27B · 裸数值	10593.9	140
Qwen3-27B · +知识	10995.2	140
Qwen3-27B · +示例	11278.6	140
Qwen3-27B · +示例·思考链(超时)	90090.7	20
Qwen3-8B · 裸数值	2803.4	140
Qwen3-8B · +知识	2873.8	140
Qwen3-8B · +示例	2825.2	140
基线：全判正常	—	140
基线：随机猜	—	140

6 结论：垂类和通用，谁更适合这件事

在“结构化传感器数值 → 类型化工业决策”这一特定任务上，垂类小网络全面、显著地优于通用大模型，而且差距不是靠堆参数或写提示词能弥补的。

6.1 五条硬结论

#	结论	数据支撑
1	裸数值喂给通用大模型，它等于瞎猜	27B·L0 平衡准确率 0.493、F1 0.000、MCC -0.085 (负值 = 还不如随机猜)
2	领域知识和示例确实能救，但有天花板	27B 从 L0 的 0.493 提升到 L1/L2 的 0.643，却仍低于决策头的 0.829；MCC 差 0.692 vs 0.286 (约 2.4 倍)
3	小模型不是“够用”，是真的不行	8B 最好档平衡准确率仅 0.543，严重度准确率 0.200；且它把样本几乎全判为故障 (召回 1.000、精确率 0.522)，属于典型“狼来了”
4	概率质量同样拉开差距	Brier 0.1202 vs 27B·L2 0.2855、8B·L2 0.4138；ECE 0.1658 vs 0.2421
5	开思考链在工业实时场景直接出局	27B 开思考链 20 条全部超过 90 秒未完成，0 条可解析；而报警分诊要求的是毫秒级响应

6.2 速度：不是一个量级

选手	单条延迟	相对决策头
哨兵决策头	0.097 ms	1×
Qwen3-8B (L2)	2825 ms	29,126×

选手	单条延迟	相对决策头
Qwen3-27B (L2)	11279 ms	116,274×
Qwen3-27B (开思考链)	> 90 000 ms (超时)	不可用

同一块 GPU、同一批数据。决策头 0.097 ms/条意味着一条产线上千个测点每秒可扫描多轮；27B 单条就要 11.3 秒，碰到报警风暴只能排队。

6.3 但通用大模型不是没用——边界要说清楚

维度	垂类决策头	通用大模型
结构化数值判定	强 (本次实测全面领先)	弱 (裸数值近乎随机)
非结构化文本 (报修工单、维修记录、手册)	做不了	强，唯一可行的选择
长尾/罕见故障 (训练数据里没有的)	无法外推	可凭通识给出合理推断
解释与报告生成	做不到	强
延迟与成本	亚毫秒、零增量成本	秒级、且随调用量线性增长
输出可控性	类型化、必然合法、概率已校准	自由文本，需解析与校验

这正是三层路由的意义，也是我们必须诚实说明的边界：高频、结构化、要求确定性的判断交给 System One (决策头)；罕见、模糊、需要语言理解与生成的才升级到生成式模型。把 27B 拿去做每秒上千条的报警分诊，既慢又不准——本次实验就是证据。

方法学提醒：随机基线的 ECE = 0.0000 (因为它恒定报 0.5，恰好匹配 50/50 的评估集)，但它的准确率只有 0.457。ECE 低 ≠ 有用，概率质量必须与判别能力一起看。

复现：cd ~/jev-service && python3 duel_bench.py | 全部数据源自 gx10-902c 节点真机实测